Zadanie 3 - Konvolučné siete a prenos vedomostí

Pavol Polednák

4. 12. 2023

Contents

1 Predstavenie **2**

2 Analýza dát, vizualizácia **3**
2.1 ImageNet analýza 3

3 Trénovanie CNN **10**
3.1 Porovnanie trénovaných modelov 11

4 Transfer learning **14**
4.1 Zhlukovanie príznakov 14
4.1.1 Cluster 9 24
4.2 Trénovanie modelu s použitím príznakov 25
4.3 Výhody použitia transfer learning 27

5 Resnet50 výsledky **28**
5.1 Nesprávne výsledky 37

1 Predstavenie

Tento projekt sa zameriava na implementáciu a hodnotenie konvolučných neurónových sietí (CNN) na úlohu klasifikácie zvierat. Využívame dataset pozostávajúci z približne 5000 trénovacích a 500 testovacích obrázkov, pričom triedy sú určené na základe adresárovej štruktúry. Prvým krokom je analýza datasetu, vrátane početností v triedach a identifikácie základných charakteristík pomocou modelov predtrénovaných na ImageNete.

Následne sme vytvorili a natrénovali vlastnú konvolučnú sieť, ktorá obsahuje minimálne dve konvolučné vrstvy a využíva rôzne regularizačné techniky vrátane Early Stoppingu na zabránenie pretrénovania. Hyperparametre boli optimalizované prostredníctvom niekoľkých experimentov, pričom výsledky sú prezentované v tabuľkovej forme.

Ďalšou časťou práce je využitie princípov transfer learningu. Použili sme modely natrénované na ImageNete na generovanie príznakov pre naše obrázky. Tieto príznaky boli následne analyzované a zhlukované, pričom sme sa zamerali na identifikáciu charakteristických skupín v rámci datasetu.

V poslednej fáze sme porovnali výsledky dosiahnuté vlastnou konvolučnou sieťou s modelmi využívajúcimi transfer learning. Tento prístup zahŕňal !!!!!! !!!!!! buď trénovanie klasifikátorov na pripravených príznakoch alebo dotrénovanie posledných vrstiev predtrénovaných modelov.

Naša práca poskytuje hĺbkovú analýzu výkonu rôznych architektúr CNN a transfer learningu v kontexte klasifikácie zvierat, pričom zdôrazňuje význam správneho nastavenia experimentu a interpretácie výsledkov.

2 Analýza dát, vizualizácia

Dataset obsahuje 90 tried zvierat, každá trieda obsahuje 54 vzoriek určených pre trénovanie a 6 vzoriek určených na testovanie.

Triedy datasetu: ['butterfly' 'cat' 'caterpillar' 'chimpanzee' 'cockroach' 'cow' 'coyote' 'crab' 'crow' 'deer' 'dog' 'dolphin' 'donkey' 'dragonfly' 'duck' 'eagle' 'elephant' 'flamingo' 'fly' 'fox' 'goat' 'goldfish' 'goose' 'gorilla' 'grasshopper' 'hamster' 'hare' 'hedgehog' 'hippopotamus' 'hornbill' 'horse' 'hummingbird' 'hyena' 'jellyfish' 'kangaroo' 'koala' 'ladybugs' 'leopard' 'lion' 'lizard' 'lobster' 'mosquito' 'moth' 'mouse' 'octopus' 'okapi' 'orangutan' 'otter' 'owl' 'ox' 'oyster' 'panda' 'parrot' 'pelecaniformes' 'penguin' 'pig' 'pigeon' 'porcupine' 'possum' 'raccoon' 'rat' 'reindeer' 'rhinoceros' 'sandpiper' 'seahorse' 'seal' 'shark' 'sheep' 'snake' 'sparrow' 'squid' 'squirrel' 'starfish' 'swan' 'tiger' 'turkey' 'turtle' 'whale' 'wolf' 'wombat' 'woodpecker' 'zebra']

2.1 ImageNet analýza

ImageNet je veľká vizuálna databáza určená na použitie vo výskume softvéru na vizuálne rozpoznávanie objektov. V priebehu rokov bolo na tejto databáze trénovaných niekoľko modelov, ktoré preukázali výborný výkon pri klasifikácii širokej škály objektov vrátane zvierat. Použitím vopred natrénovaného modelu využijeme znalosti, ktoré sa model už naučil z rozsiahleho a rozmanitého súboru údajov.

Existuje viacero možností, my sme si zvolili model ResNet50. Keďže množina našich tried sa líši od množiny na kt. bol ResNet50 trénovaný, hodnotenie výsledkov nie je triviálne. Táto sekcia je veľmi dlhá a preto si dovolím uviesť výsledky na záver, v sekcii 5.

antelope
okapi
rhinoceros
swan
elephant
pelecaniformes
koala
crab
pigeon
fox
woodpecker
hippopotamus
gorilla
seal
otter

chimpanzee
caterpillar
moth
ox
whale
cockroach
mosquito
boar
goat
kangaroo
wombat
goldfish
fly
hare
raccoon

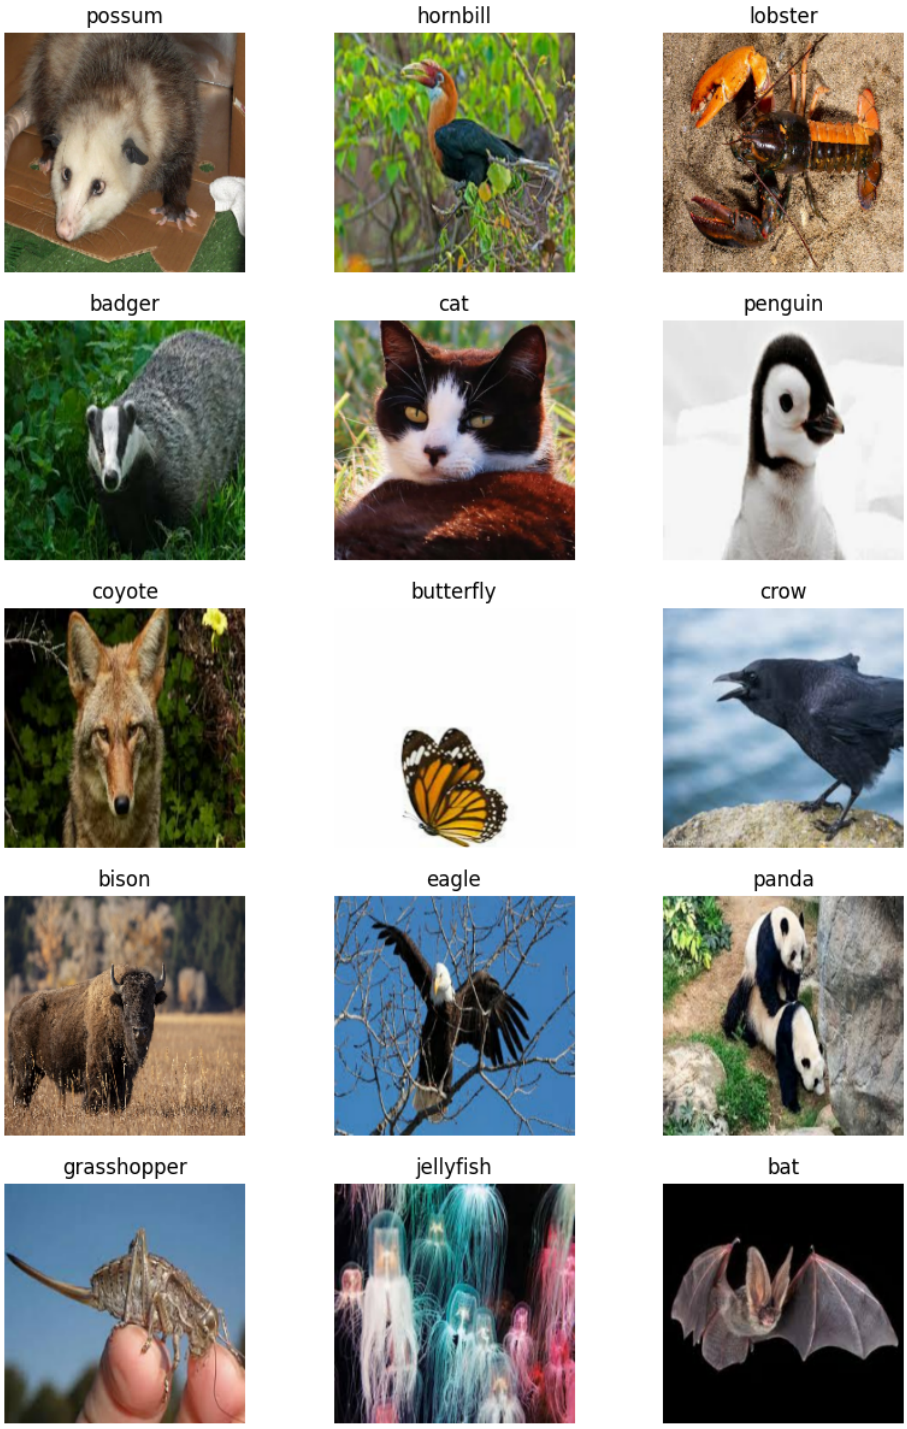
possum
hornbill
lobster
badger
cat
penguin
coyote
butterfly
crow
bison
eagle
panda
grasshopper
jellyfish
bat

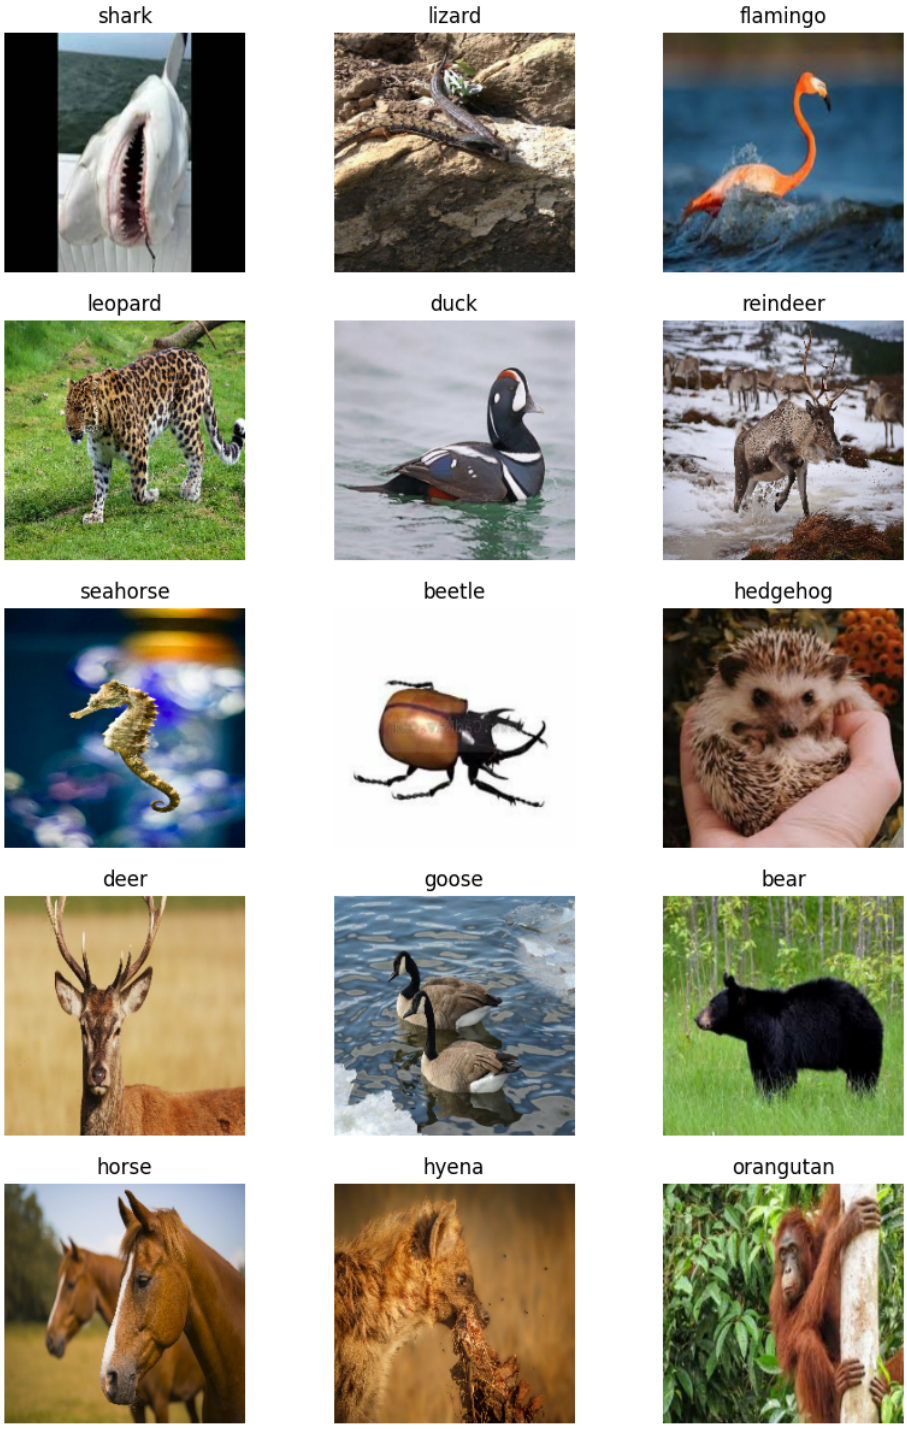
shark
lizard
flamingo
leopard
duck
reindeer
seahorse
beetle
hedgehog
deer
goose
bear
horse
hyena
orangutan

dog
donkey
bee
snake
sandpiper
hamster
turtle
squid
parrot
ladybugs
lion
zebra
sparrow
dragonfly
owl

octopus
oyster
mouse
cow
wolf
dolphin
porcupine
hummingbird
tiger
sheep
rat
turkey
pig
starfish
squirrel

3 Trénovanie CNN

Príprava Dát: Začíname prípravou trénovacej, validačnej a testovacej množiny. Dôležitým krokom je aj augmentácia dát a ich normalizácia, čo zvyšuje schopnosť modelu generalizovať a zlepšuje jeho výkon.

Architektúra Siete: Navrhujeme architektúru siete s minimálne dvoma konvolučnými vrstvami. Zámerom je extrahovať relevantné vlastnosti z obrazových dát pre účely klasifikácie.

Regularizácia: Aplikujeme rôzne techniky regularizácie, aby sme predišli pretrénovaniu siete. Medzi tieto techniky môže patriť napríklad Dropout alebo Early Stopping.

Hyperparametre: Experimentujeme s rôznymi konfiguráciami hyperparametrov, aby sme našli najefektívnejšie nastavenie pre našu sieť.

Vyhodnotenie a Analýza: Po trénovaní modelu dôkladne analyzujeme jeho výkonnosť. Používame metriky ako matica zámen, trénovacie a validačné krivky na posúdenie presnosti a spoľahlivosti modelu.

Význam v Rámci Celkového Projektu:

Tento krok je nevyhnutný pre porozumenie základných princípov hlbokého učenia a konvolučných neurónových sietí. Trénovanie vlastnej CNN na klasifikáciu zvierat poskytuje moožnosť získať základné znalosti, ktoré sú následne aplikovateľné v ďalšej častia projektu, pri prechode na techniky transfer learning. Výsledky získané v tejto časti budeme porovnávať s výsledkom modelu, utilizujúceho vektory príznakov.

3.1 Porovnanie trénovaných modelov

Úspešnosť modelu hodnotená cez model.evaluate()

Index	Úspešnosť trénovania	Úspešnosť testovania
1	0.2594907283782959	0.14629629254341125
2	0.09791667014360428	0.07407407462596893
3	0.29212963581085205	0.14259259402751923
4	0.07615740597248077	0.07962962985038757

Table 1: Porovnanie výsledkov modelov

Všetky modely boli trénované s nasledovnými vlastnosťami:

- Optimalizátor: Adam
- Stratová funkcia: Sparse Categorical Crossentropy
- Počet epoch: 10
- Skoré zastavenie: Použité s trpezlivosťou 5 epoch a obnovením najlepších váh

Ako víťazný sme zvolili **Model 1**:

- Rescaling vrstva (1. / 255)
- Konvolučná vrstva: 16 filtrov, (3x3), aktivácia 'relu'
- MaxPooling2D
- Konvolučná vrstva: 32 filtrov, (3x3), aktivácia 'relu'
- MaxPooling2D
- Flatten vrstva
- Hustá vrstva: 64 neurónov, aktivácia 'relu', regularizácia L2 (0.01)
- Výstupná hustá vrstva: počet tried, aktivácia 'softmax'

- Model 2: Pridané vrstvy: RandomFlip ("horizontal") a RandomRotation (0.1)
- Model 3: Zmena v konvolučných vrstvách - prvá vrstva má 32 filtrov, druhá 64 filtrov
- Model 4: Zmena v hustých vrstvách: Dve husté vrstvy (128 a 64 neurónov), obe s regularizáciou L2 (0.01)

Výsledky Modelu 1:

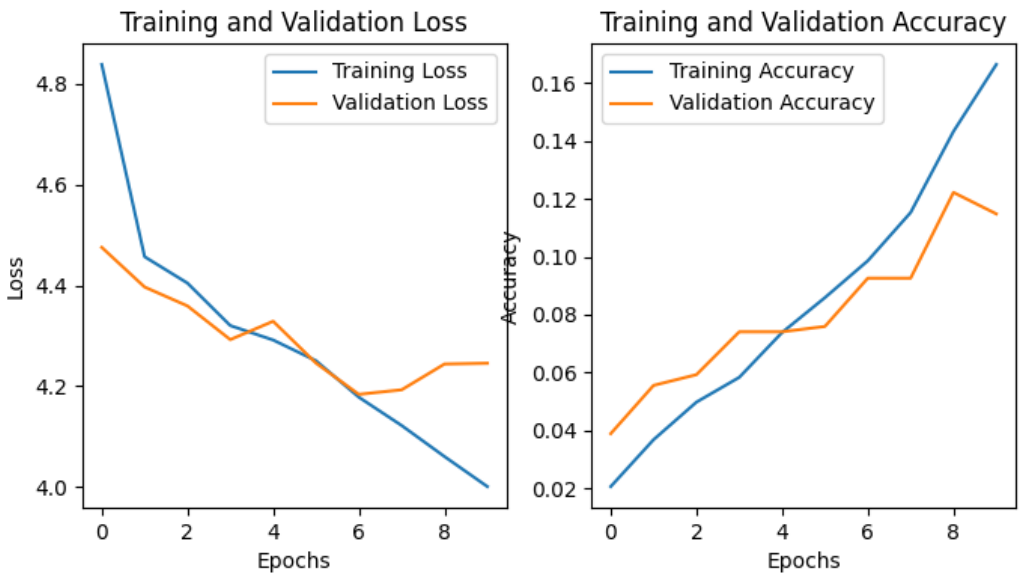

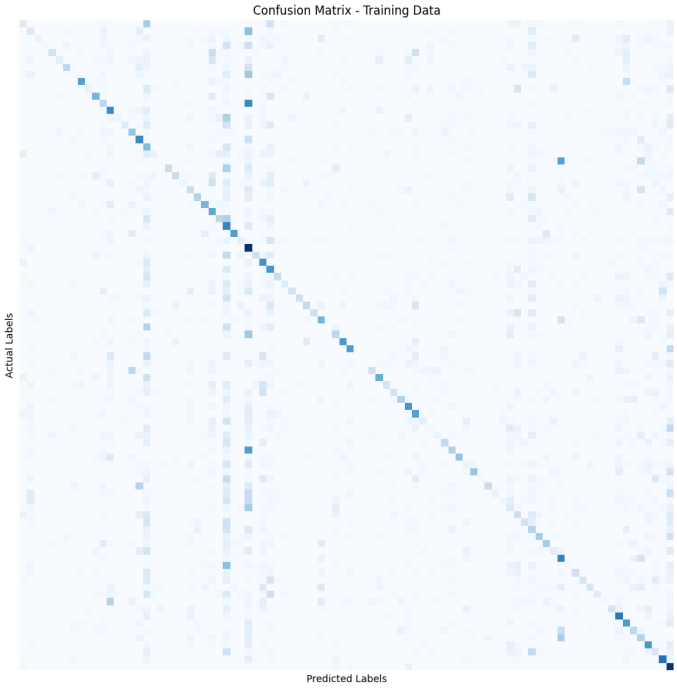
Confusion Matrix - Training Data
Actual Labels
Predicted Labels

Confusion Matrix - Testing Data
Actual Labels
Predicted Labels

4 Transfer learning

Transfer learning je technika, ktorá výrazne zlepšuje výkonnosť strojového učenia vďaka využitiu predtrénovaných modelov. V tejto fáze projektu sa zameriavame na aplikáciu tejto techniky na klasifikáciu zvierat, pričom hlavným cieľom je dosiahnuť lepšie výsledky ako pri našom pôvodne vytvorenom konvolučnom modeli.

- Využitie Predtrénovanej Siete: Začneme využitím siete predtrénovanej na datasete ImageNet. Tento model využijeme na extrakciu príznakov obrázkov namiesto ich priamej klasifikácie. Využijeme sieť ResNet50, tak ako v sekcii 2.1
- Extrakcia a Ukladanie Príznakov: Každý obrázok zo sady prejde cez sieť, ktorá generuje vektor príznakov. Tieto príznaky budú uložené do dataframe-u, spolu s cestou k obrázku a výstupnou triedou.

Pre každý zhluk zobrazíme skupinu vzoriek a reprezentačnú vzorku (najbližšie centroidu zhluku).

4.1 Zhlukovanie príznakov

- Zhlukovanie príznakov: Aplikujeme zhlukovací algoritmus na vygenerované príznaky, čím získame zhluky obrázkov s podobnými charakteristikami. Tento prístup nám umožní lepšie pochopiť distribúciu dát.
- Vizualizácia a analýza zhlukov: Pre každý zhluk zobrazíme podmnožinu obrázkov a vytvoríme priemerný obrázok, aby sme získali lepší prehľad o charakteristikách zhlukov
- Vyhodnotenie zhlukov: Analyzujeme výsledky zhlukovania, s cieľom zistiť, aké typy obrázkov sa v jednotlivých zhlukoch nachádzajú (napr. zvieratá so štyrmi nohami, obrázky s veľkým podielom oblohy atď.)
- Zvolili sme si algortimus K-means. Je to jeden z najjednoduchších a najčastejšie používaných metód zhlukovania v analýze dát a strojovom učení. Cieľom K-means je zoskupiť podobné dátové body dokopy a odhaliť základné vzory. Na dosiahnutie tohto cieľa hľadá K-means pevný počet (k) zhlukov v datasete. Algoritmus pracuje tak, že náhodne inicializuje k centroidov, ktoré sú body v priestore reprezentujúce stredy zhlukov. Každý dátový bod je potom priradený k najbližšiemu centroidu a každá skupina bodov priradená centroidu je zhluk. Po priradení všetkých bodov sú pozície k centroidov prepočítané na základe bodov v každom zhluku. Tento proces sa opakuje iteratívne, až kým sa centroidy výrazne nepohnú, čo naznačuje, že zhluky sú tak dobré, ako môžu byť s danými dátami.

Cluster 0

Tento zhluk obsahuje vzorky:

- dvojnohé živočíchy, krídla (vtáky)

Cluster 1

Tento zhluk obsahuje vzorky:

- štvorjonohé živočíchy, nevýrazné farby, béžová

Cluster 2

Tento zhluk obsahuje vzorky:

- Viacfarebnosť, výrazné vzory (tiger, zebra, okapi)

Cluster 3

Tento zhluk obsahuje vzorky:

- Oválový tvar, výrazný kontrast farieb

Cluster 4

Tento zhluk obsahuje vzorky:

- Nevýrazné farby, všežravce, srsť

Cluster 5

Tento zhluk obsahuje vzorky:

- Hmyz, krídla

Cluster 6

Tento zhluk obsahuje vzorky:

- Vodné živočíchy

Cluster 7

Tento zhluk obsahuje vzorky:

- Spoločenský živočích (veľká frekvencia fotografií s > 1 jedincami), vysoký jas fotografie?

Cluster 8

Tento zhluk obsahuje vzorky:

- Štvornohé, bylinožravce

4.1.1 Cluster 9

Tento zhluk obsahuje vzorky:

- Domáci miláčikovia, pozadím je interiér

4.2 Trénovanie modelu s použitím príznakov

- Výber a tréning klasifikátora: Na pripravených príznakoch trénujeme vybraný klasifikátor. Zvolili sme si random forest. Pri tomto kroku je dôležité dosiahnuť lepšie výsledky ako s pôvodným konvolučným modelom.
- Prečo? Pri použití týchto predtrénovaných príznakov pre klasifikáciu alebo ďalšiu analýzu sa často dosahuje lepší výkon v porovnaní s modelmi trénovanými od základu. To je spôsobené tým, že modely využívajúce transfer learning už majú "predstavu" o dôležitých charakteristikách obrázkov, čo umožňuje efektívnejšie učenie sa špecifických údajov nového datasetu.
- Vyhodnotenie a analýza: Dôkladne vyhodnotíme výsledky, zobrazíme priebehy tréningu, konfúzne matice a analyzujeme úspešnosť na tréningovej a testovacej množine. Zameriame sa na identifikáciu a pochopenie chýb modelu.

Finálny model:

- **Výber príznakov a štítkov:**
  - $X = df_features.iloc[:, 1 : -2]$ - výber príznakov z DataFrame.
  - $y = df_features['label']$ - výber štítkov (cieľových hodnôt).
- **Trénovanie modelu:**
  - Rozdelenie na trénovacie a testovacie dáta v pomere 80% / 20%.
  - Použitie RandomForestClassifier na trénovanie.
  - Predikcie na trénovacích a testovacích dátach.
  - Výpočet presnosti modelu na trénovacích a testovacích dátach.
- **Úspešnosť modelu hodnotená cez accuracy_score**
  - Training Accuracy: 0.9997685185185186
  - Test Accuracy: 0.8333333333333334
  - Bolo zaznamenané výrazné pretrénovanie a teda bolo pri vypracovaní zadania niečo prehliadnuté. Úspešnosť na testovacích dátach je však aj tak veľmi vysoká.

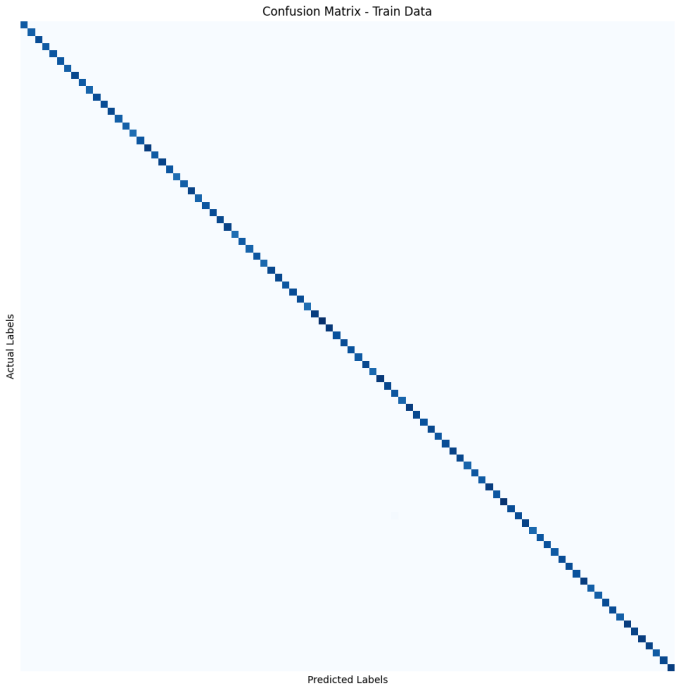
Confusion Matrix - Train Data
Actual Labels
Predicted Labels

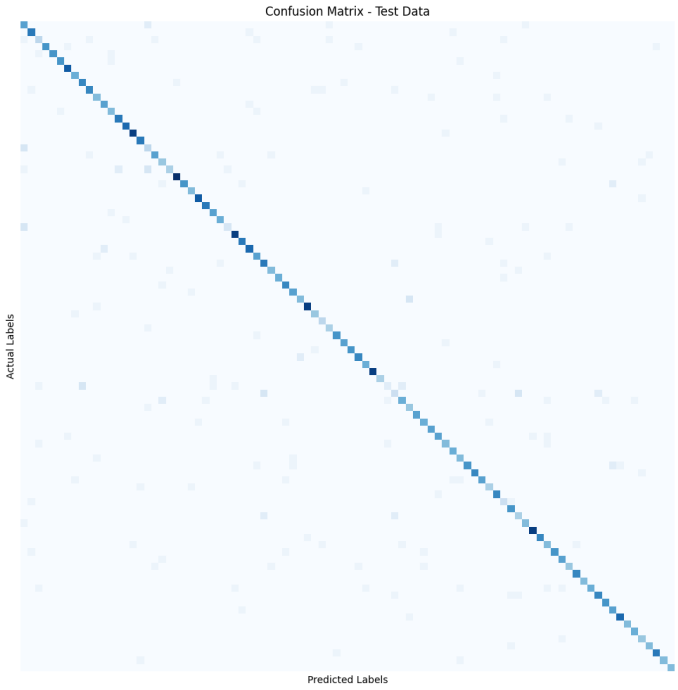
Confusion Matrix - Test Data
Actual Labels
Predicted Labels

4.3 Výhody použitia transfer learning

- Efektívnosť: Využitím transfer learningu sme schopní výrazne znižovať výpočtovú náročnosť. Predtrénované modely už majú naučené všeobecné charakteristiky dát, čo nám umožňuje efektívnejšie trénovať model na konkrétnu úlohu.
- Zrýchlenie tréningu: Keďže model už má naučené základné vzorce, tréning na špecifickú úlohu je rýchlejší a vyžaduje menej dát.
- Zlepšenie výsledkov: Transfer learning často vedie k lepším výsledkom, pretože model využíva vysoko sofistikované vzorce získané z veľkého množstva dát.

5 Resnet50 výsledky

Class: antelope

Top Prediction	Count	Score
gazelle	27	0.4399
impala	24	0.3274
hartebeest	5	0.1365
wallaby	2	0.0121
mountain_bike	1	0.0031

Class: badger

Top Prediction	Count	Score
badger	51	0.8177
groenendael	3	0.0232
guenon	1	0.0086
hog	1	0.0038
grey_fox	1	0.0115

Class: bat

Top Prediction	Count	Score
hummingbird	5	0.0456
robin	3	0.0217
ringlet	3	0.0230
kite	3	0.0227
isopod	2	0.0129

Class: bear

Top Prediction	Count	Score
brown_bear	36	0.5711
American_black_bear	18	0.2750
hook	1	0.0010
ice_bear	1	0.0182
fox_squirrel	1	0.0026

Class: bee

Top Prediction	Count	Score
bee	48	0.7315
honeycomb	3	0.0518
cardoon	2	0.0325
isopod	1	0.0046
garden_spider	1	0.0045

Class: beetle

Top Prediction	Count	Score
rhinoceros_beetle	18	0.2919
leaf_beetle	9	0.1286
ground_beetle	8	0.1363
dung_beetle	4	0.0638
tiger_beetle	3	0.0359

Class: bison

Top Prediction	Count	Score
bison	55	0.8872
hartebeest	1	0.0036
African_elephant	1	0.0030
American_black_bear	1	0.0086
ox	1	0.0209

Class: boar

Top Prediction	Count	Score
wild_boar	45	0.5676
hog	5	0.2545
warthog	4	0.0703
African_hunting_dog	1	0.0035
brown_bear	1	0.0078

Class: butterfly

Top Prediction	Count	Score
monarch	27	0.4529
lycaenid	10	0.1169
admiral	6	0.0569
ringlet	4	0.0692
hair_slide	3	0.0198

Class: cat

Top Prediction	Count	Score
Egyptian_cat	19	0.2041
tabby	14	0.1864
lynx	3	0.0413
tiger_cat	3	0.0984
Persian_cat	3	0.0356

Class: caterpillar

Top Prediction	Count	Score
centipede	7	0.1105
lacewing	7	0.0653
leaf_beetle	3	0.0174
sea_slug	3	0.0332
ringlet	3	0.0116

Class: chimpanzee

Top Prediction	Count	Score
chimpanzee	55	0.7612
gorilla	2	0.0638
pot	1	0.0038
bloodhound	1	0.0032
guenon	1	0.0219

Class: cockroach

Top Prediction	Count	Score
cockroach	55	0.8705
cricket	3	0.0444
hair_slide	1	0.0036
Gila_monster	1	0.0128
-	-	-

Class: cow

Top Prediction	Count	Score
ox	28	0.3566
Great_Dane	8	0.0738
ostrich	2	0.0292
sorrel	2	0.0326
Arabian_camel	2	0.0158

Class: coyote

Top Prediction	Count	Score
coyote	45	0.6481
red_wolf	3	0.0680
dingo	2	0.0211
cougar	1	0.0055
wallaby	1	0.0171

Class: crab

Top Prediction	Count	Score
king_crab	17	0.2373
rock_crab	15	0.2513
Dungeness_crab	14	0.2251
fiddler_crab	7	0.1026
indigo_bunting	2	0.0218

Class: crow

Top Prediction	Count	Score
black_grouse	15	0.1383
magpie	11	0.1236
water_ouzel	8	0.0978
vulture	8	0.1055
kite	4	0.0575

Class: deer

Top Prediction	Count	Score
gazelle	22	0.2744
ibex	12	0.1557
hartebeest	5	0.0880
impala	5	0.1357
wallaby	4	0.0283

Class: dog

Top Prediction	Count	Score
golden_retriever	7	0.1183
Labrador_retriever	3	0.0417
Great_Dane	3	0.0356
Saluki	3	0.0521
borzoi	3	0.0253

Class: dolphin

Top Prediction	Count	Score
killer_whale	12	0.1590
tiger_shark	7	0.0960
sea_lion	7	0.0995
dugong	6	0.0729
grey_whale	6	0.0903

Class: donkey

Top Prediction	Count	Score
hartebeest	11	0.1100
llama	9	0.1088
ibex	6	0.0772
worm_fence	5	0.0461
sorrel	4	0.0346

Class: flamingo

Top Prediction	Count	Score
flamingo	49	0.7659
hook	2	0.0229
cradle	1	0.0088
seashore	1	0.0095
daisy	1	0.0043

Class: dragonfly

Top Prediction	Count	Score
dragonfly	44	0.6639
damselfly	10	0.1839
bolo_tie	2	0.0276
safety_pin	1	0.0079
lycaenid	1	0.0070

Class: fly

Top Prediction	Count	Score
fly	50	0.7813
dragonfly	4	0.0395
hermit_crab	1	0.0089
ringlet	1	0.0140
lacewing	1	0.0077

Class: duck

Top Prediction	Count	Score
drake	28	0.4027
goose	14	0.1797
red-breasted_merganser	2	0.0378
weasel	2	0.0068
albatross	2	0.0332

Class: fox

Top Prediction	Count	Score
red_fox	37	0.5155
kit_fox	9	0.1868
grey_fox	5	0.0848
gazelle	3	0.0229
dhole	2	0.0334

Class: eagle

Top Prediction	Count	Score
bald_eagle	55	0.8646
kite	4	0.0934
chime	1	0.0028
-	-	-
-	-	-

Class: goat

Top Prediction	Count	Score
ibex	10	0.1217
Ibizan_hound	9	0.0600
ram	7	0.0971
hartebeest	5	0.0574
ox	3	0.0431

Class: elephant

Top Prediction	Count	Score
African_elephant	26	0.3849
Indian_elephant	22	0.3163
tusker	9	0.2170
bison	2	0.0197
totem_pole	1	0.0048

Class: goldfish

Top Prediction	Count	Score
goldfish	54	0.8541
beaker	2	0.0189
ski_mask	1	0.0155
vase	1	0.0117
goblet	1	0.0039

Class: goose

Top Prediction	Count	Score
goose	56	0.8412
black_stork	2	0.0324
albatross	1	0.0121
kite	1	0.0090
-	-	-

Class: gorilla

Top Prediction	Count	Score
gorilla	55	0.8363
American_black_bear	1	0.0087
cocker_spaniel	1	0.0052
chimpanzee	1	0.0338
howler_monkey	1	0.0153

Class: grasshopper

Top Prediction	Count	Score
grasshopper	43	0.5965
cricket	9	0.2325
harvestman	3	0.0344
bustard	2	0.0077
walking_stick	1	0.0064

Class: hamster

Top Prediction	Count	Score
hamster	49	0.7488
coral_fungus	1	0.0161
Afghan_hound	1	0.0020
Angora	1	0.0112
candle	1	0.0021

Class: hare

Top Prediction	Count	Score
hare	51	0.7625
wood_rabbit	3	0.0955
wool	1	0.0096
Angora	1	0.0165
dhole	1	0.0072

Class: hedgehog

Top Prediction	Count	Score
porcupine	48	0.7453
black-footed_ferret	4	0.0381
titi	1	0.0024
snow_leopard	1	0.0033
bolo_tie	1	0.0118

Class: hippopotamus

Top Prediction	Count	Score
hippopotamus	52	0.8128
triceratops	2	0.0345
warthog	2	0.0328
Doberman	1	0.0123
tick	1	0.0151

Class: hornbill

Top Prediction	Count	Score
hornbill	52	0.7996
vulture	2	0.0250
bald_eagle	2	0.0199
black_stork	1	0.0242
totem_pole	1	0.0109

Class: horse

Top Prediction	Count	Score
sorrel	27	0.3845
Saluki	8	0.0937
hartebeest	4	0.0642
Arabian_camel	4	0.0465
Mexican_hairless	3	0.0173

Class: hummingbird

Top Prediction	Count	Score
hummingbird	53	0.8482
bee_eater	3	0.0468
sulphur_butterfly	1	0.0051
jacamar	1	0.0373
brambling	1	0.0034

Class: hyena

Top Prediction	Count	Score
hyena	54	0.8202
llama	2	0.0188
wallaby	1	0.0115
Great_Dane	1	0.0084
sorrel	1	0.0068

Class: jellyfish

Top Prediction	Count	Score
jellyfish	56	0.8750
tick	2	0.0158
table_lamp	1	0.0083
lionfish	1	0.0024
-	-	-

Class: kangaroo

Top Prediction	Count	Score
wallaby	35	0.5120
gazelle	7	0.0895
hare	5	0.0938
hartebeest	3	0.0456
impala	2	0.0344

Class: koala

Top Prediction	Count	Score
koala	54	0.8154
wallaby	2	0.0166
teddy	1	0.0162
fox_squirrel	1	0.0318
slug	1	0.0062

Class: ladybugs

Top Prediction	Count	Score
ladybug	48	0.7280
leaf_beetle	8	0.1476
monarch	1	0.0023
starfish	1	0.0160
hook	1	0.0038

Class: leopard

Top Prediction	Count	Score
leopard	48	0.7115
cheetah	4	0.0952
jaguar	4	0.1091
snow_leopard	2	0.0326
meerkat	1	0.0073

Class: lion

Top Prediction	Count	Score
lion	51	0.7757
fox_squirrel	1	0.0038
hartebeest	1	0.0044
Arabian_camel	1	0.0307
warthog	1	0.0066

Class: lizard

Top Prediction	Count	Score
agama	10	0.1616
banded_gecko	7	0.0924
alligator_lizard	6	0.0928
whiptail	5	0.0619
American_chameleon	4	0.0611

Class: lobster

Top Prediction	Count	Score
American_lobster	39	0.6041
crayfish	9	0.1674
spiny_lobster	8	0.1115
sea_cucumber	1	0.0031
vase	1	0.0067

Class: mosquito

Top Prediction	Count	Score
barn_spider	13	0.1048
harvestman	9	0.0952
fly	6	0.0735
tiger_beetle	5	0.0566
dragonfly	4	0.0265

Class: moth

Top Prediction	Count	Score
ringlet	12	0.1337
sulphur_butterfly	6	0.0668
lacewing	4	0.0311
ringneck_snake	2	0.0094
earthstar	2	0.0182

Class: mouse

Top Prediction	Count	Score
hamster	19	0.2036
mousetrap	8	0.1194
wood_rabbit	8	0.1144
fox_squirrel	5	0.0421
weasel	4	0.0614

Class: octopus

Top Prediction	Count	Score
starfish	16	0.2001
hook	3	0.0375
electric_ray	3	0.0185
hair_slide	3	0.0178
frilled_lizard	3	0.0493

Class: okapi

Top Prediction	Count	Score
sorrel	20	0.2220
zebra	19	0.2421
gazelle	5	0.0486
hartebeest	3	0.0404
wallaby	2	0.0310

Class: orangutan

Top Prediction	Count	Score
orangutan	58	0.9246
lesser_panda	1	0.0082
barrow	1	0.0166
-	-	-
-	-	-

Class: otter

Top Prediction	Count	Score
otter	47	0.6813
ice_bear	3	0.0430
sea_lion	2	0.0232
warthog	1	0.0099
bucket	1	0.0031

Class: owl

Top Prediction	Count	Score
great_grey_owl	27	0.3710
vulture	4	0.0277
pelican	3	0.0191
ruffed_grouse	2	0.0130
prairie_chicken	2	0.0386

Class: ox

Top Prediction	Count	Score
ox	32	0.4896
oxcart	7	0.1121
fountain	3	0.0319
hartebeest	3	0.0322
triceratops	2	0.0163

Class: oyster

Top Prediction	Count	Score
hen-of-the-woods	9	0.0863
plate	7	0.0754
bolo_tie	6	0.0471
bottlecap	3	0.0275
earthstar	3	0.0257

Class: panda

Top Prediction	Count	Score
giant_panda	57	0.8900
badger	1	0.0210
killer_whale	1	0.0044
standard_poodle	1	0.0120
-	-	-

Class: parrot

Top Prediction	Count	Score
macaw	32	0.4754
lorikeet	13	0.1505
African_grey	5	0.0879
bee_eater	3	0.0464
-	-	-

Class: pelecaniformes

Top Prediction	Count	Score
pelican	51	0.8180
hornbill	2	0.0213
red-backed_sandpiper	1	0.0063
vulture	1	0.0098
limpkin	1	0.0076

Class: penguin

Top Prediction	Count	Score
king_penguin	49	0.7615
goose	3	0.0373
seashore	2	0.0206
ice_bear	2	0.0187
bustard	1	0.0067

Class: pig

Top Prediction	Count	Score
hog	50	0.7120
wild_boar	3	0.0525
wallaby	1	0.0060
warthog	1	0.0131
whippet	1	0.0025

Class: pigeon

Top Prediction	Count	Score
African_grey	8	0.0945
partridge	5	0.0438
black_grouse	5	0.0653
European_gallinule	5	0.0392
hen	4	0.0196

Class: porcupine

Top Prediction	Count	Score
porcupine	57	0.9238
baboon	1	0.0116
abaya	1	0.0055
armadillo	1	0.0089
-	-	-

Class: possum

Top Prediction	Count	Score
black-footed_ferret	12	0.0958
badger	9	0.0832
hamster	6	0.0478
weasel	5	0.0630
fox_squirrel	4	0.0322

Class: raccoon

Top Prediction	Count	Score
badger	19	0.1547
grey_fox	11	0.1126
polecat	5	0.0483
Madagascar_cat	4	0.0449
fox_squirrel	3	0.0220

Class: rat

Top Prediction	Count	Score
hamster	17	0.1725
mousetrap	7	0.0879
mink	7	0.1067
weasel	6	0.0558
fox_squirrel	4	0.0376

Class: reindeer

Top Prediction	Count	Score
ibex	28	0.3285
bighorn	7	0.0974
gazelle	6	0.0870
dogsled	5	0.0575
llama	3	0.0152

Class: rhinoceros

Top Prediction	Count	Score
warthog	11	0.1492
Indian_elephant	9	0.1116
triceratops	8	0.1117
bison	6	0.0627
hippopotamus	4	0.0497

Class: sandpiper

Top Prediction	Count	Score
red-backed_sandpiper	38	0.5841
dowitcher	13	0.1846
redshank	4	0.0962
bustard	2	0.0191
ruddy_turnstone	2	0.0473

Class: seahorse

Top Prediction	Count	Score
coral_fungus	5	0.0517
sea_slug	5	0.0646
coral_reef	5	0.0521
nematode	4	0.0285
banded_gecko	4	0.0339

Class: seal

Top Prediction	Count	Score
sea_lion	48	0.6469
ice_bear	3	0.0447
snow_leopard	2	0.0129
leatherback_turtle	2	0.0123
-	-	-

Class: shark

Top Prediction	Count	Score
great_white_shark	27	0.4467
tiger_shark	21	0.3420
hammerhead	6	0.0985
sea_lion	2	0.0140
coho	1	0.0084

Class: sheep

Top Prediction	Count	Score
ram	37	0.5120
Arabian_camel	3	0.0277
llama	3	0.0479
ocarina	2	0.0178
teddy	2	0.0061

Class: snake

Top Prediction	Count	Score
Indian_cobra	15	0.2080
ringneck_snake	7	0.0762
thunder_snake	5	0.0577
night_snake	4	0.0715
king_snake	4	0.0479

Class: sparrow

Top Prediction	Count	Score
brambling	31	0.3415
house_finch	7	0.0867
bulbul	3	0.0509
partridge	3	0.0461
quail	2	0.0238

Class: squid

Top Prediction	Count	Score
sea_slug	5	0.0369
crayfish	4	0.0347
goldfish	3	0.0257
whistle	2	0.0091
king_crab	2	0.0076

Class: squirrel

Top Prediction	Count	Score
fox_squirrel	50	0.7758
triceratops	2	0.0094
Irish_terrier	2	0.0235
book_jacket	1	0.0040
armadillo	1	0.0081

Class: starfish

Top Prediction	Count	Score
starfish	52	0.8182
jellyfish	2	0.0290
prayer_rug	2	0.0322
Christmas_stocking	1	0.0058
knot	1	0.0077

Class: swan

Top Prediction	Count	Score
goose	18	0.2247
American_egret	11	0.1472
black_swan	10	0.1551
pelican	6	0.0688
lakeside	3	0.0370

Class: tiger

Top Prediction	Count	Score
tiger	56	0.7950
garden_spider	1	0.0104
snow_leopard	1	0.0063
zebra	1	0.0193
impala	1	0.0060

Class: turkey

Top Prediction	Count	Score
prairie_chicken	12	0.1431
hen	11	0.1328
vulture	7	0.0758
black_grouse	4	0.0560
cock	4	0.0561

Class: turtle

Top Prediction	Count	Score
loggerhead	35	0.4698
leatherback_turtle	10	0.2236
box_turtle	5	0.0777
terrapin	5	0.0869
swimming_trunks	1	0.0122

Class: whale

Top Prediction	Count	Score
grey_whale	22	0.3240
great_white_shark	10	0.1152
killer_whale	8	0.1490
dugong	5	0.0718
tiger_shark	3	0.0514

Class: wolf

Top Prediction	Count	Score
timber_wolf	40	0.4952
groenendael	5	0.0539
coyote	4	0.0759
red_wolf	3	0.0870
white_wolf	3	0.0623

Class: wombat

Top Prediction	Count	Score
wombat	51	0.8048
wild_boar	2	0.0244
beaver	2	0.0247
hare	1	0.0067
marmot	1	0.0067

Class: woodpecker

Top Prediction	Count	Score
hornbill	14	0.1388
black_grouse	6	0.0676
bee_eater	6	0.0694
quail	5	0.0559
bulbul	4	0.0473

Class: zebra

Top Prediction	Count	Score
zebra	58	0.9441
cheetah	1	0.0119
limpkin	1	0.0047
-	-	-
-	-	-

5.1 Nesprávne výsledky

Správna trieda	Top predpoveď ResNet50
antelope	gazelle
bat	hummingbird
butterfly	monarch
caterpillar	centipede
cow	ox
crow	black_grouse
deer	gazelle
dog	golden_retriever
dolphin	killer_whale
donkey	hartebeest
duck	drake
goat	ibex
hedgehog	porcupine
horse	sorrel
kangaroo	wallaby
ladybugs	ladybug
lizard	agama
mosquito	barn_spider
moth	ringlet
mouse	hamster
octopus	starfish
okapi	sorrel
oyster	hen-of-the-woods
parrot	macaw
pelecaniformes	pelican
pig	hog
pigeon	African_grey
possum	black-footed_ferret
raccoon	badger
rat	hamster
reindeer	ibex
rhinoceros	warthog
seahorse	coral_fungus
seal	sea_lion
sheep	ram
snake	Indian_cobra
sparrow	brambling
squid	sea_slug
swan	goose
turkey	prairie_chicken
turtle	loggerhead
woodpecker	hornbill

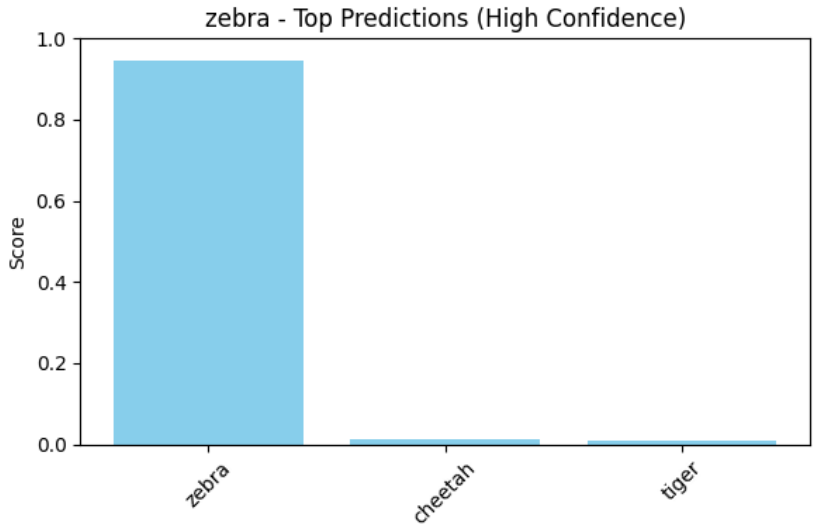
zebra - Top Predictions (High Confidence)
Score
1.0
0.8
0.6
0.4
0.2
0.0
zebra
cheetah
tiger

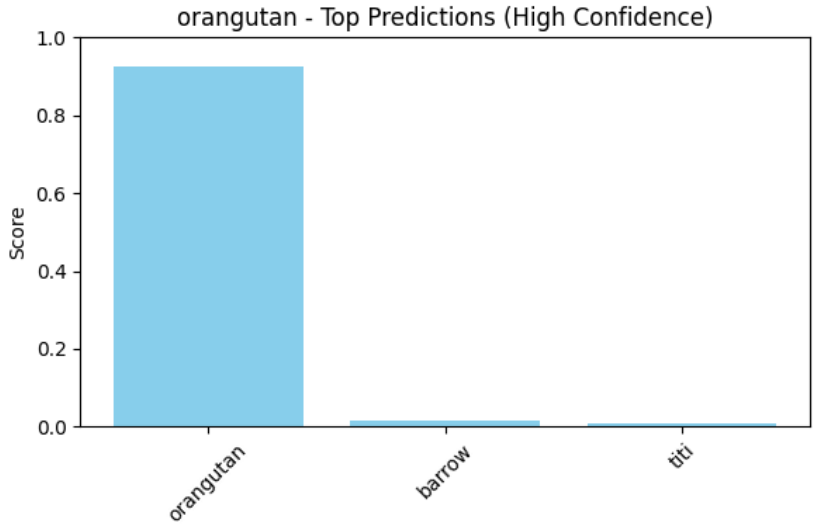
orangutan - Top Predictions (High Confidence)
Score
1.0
0.8
0.6
0.4
0.2
0.0
orangutan
barrow
titi

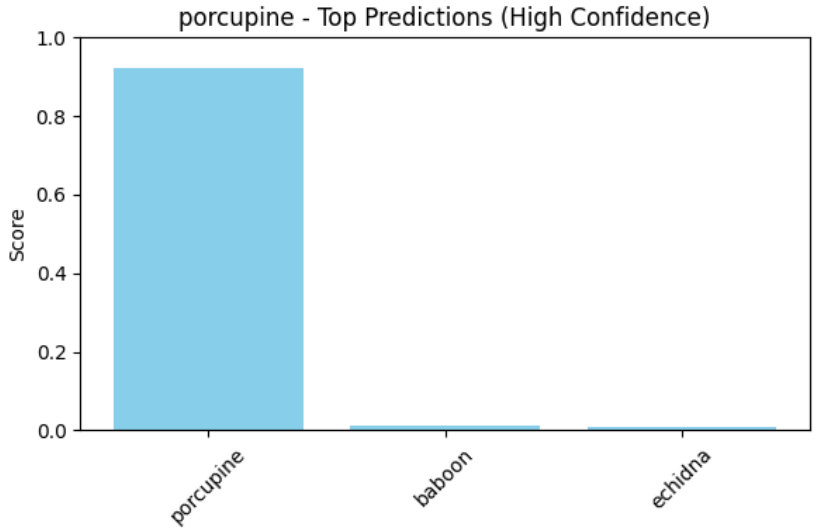
porcupine - Top Predictions (High Confidence)
Score
1.0
0.8
0.6
0.4
0.2
0.0
porcupine
baboon
echidna

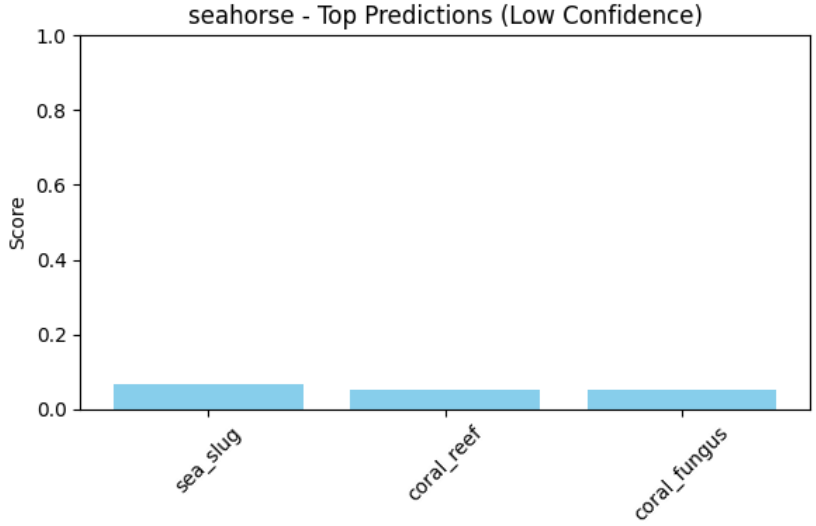
seahorse - Top Predictions (Low Confidence)
Score
1.0
0.8
0.6
0.4
0.2
0.0
sea_slug
coral_reef
coral_fungus

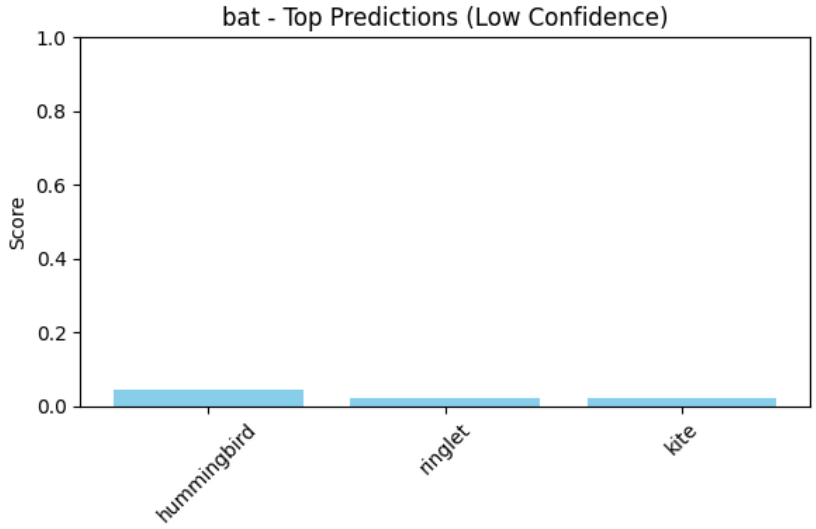
bat - Top Predictions (Low Confidence)
Score
1.0
0.8
0.6
0.4
0.2
0.0
hummingbird
ringlet
kite

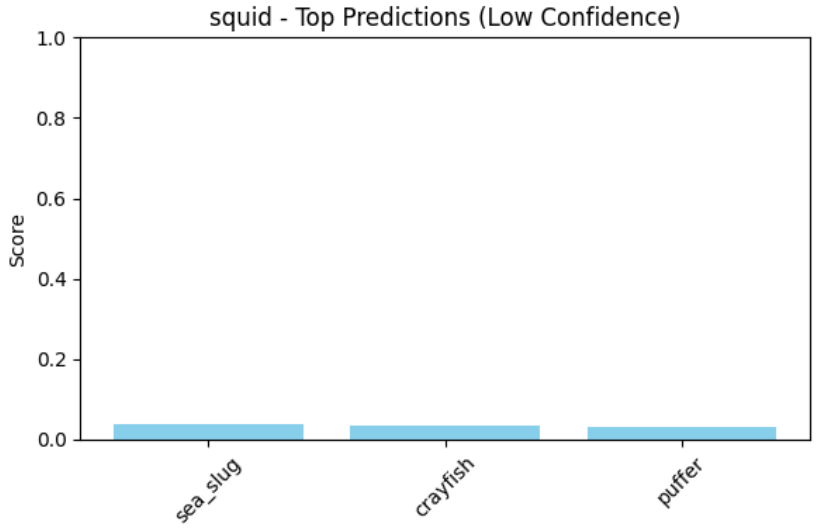
squid - Top Predictions (Low Confidence)
Score
1.0
0.8
0.6
0.4
0.2
0.0
sea_slug
crayfish
puffer

badger

antelope

bat

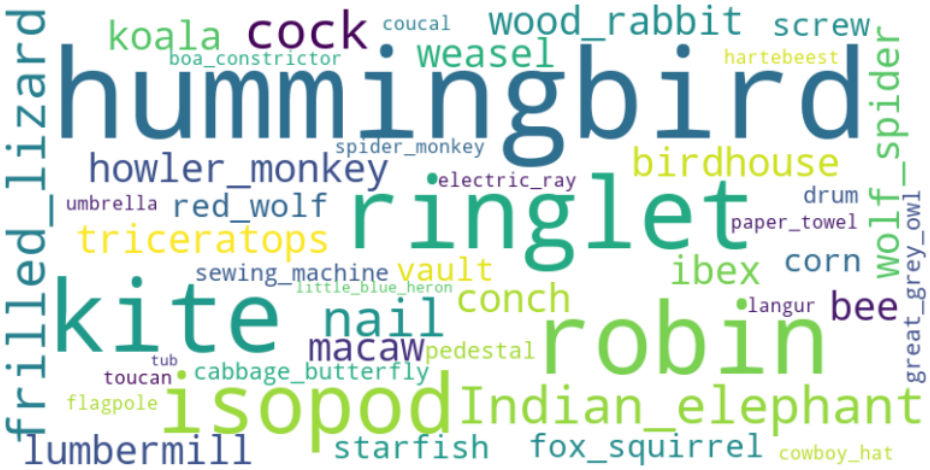

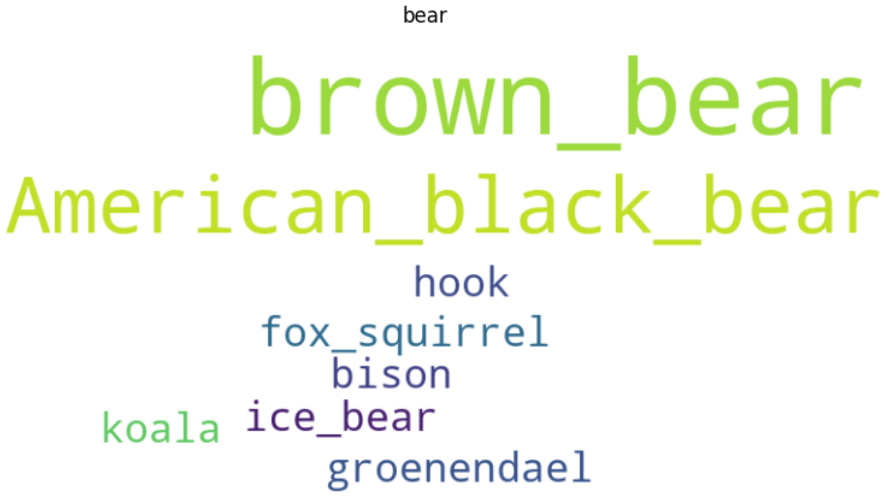
bear
brown_bear
American_black_bear
hook
fox_squirrel
bison
koala
ice_bear
groenendael